Bu kısımda L2 regularization'ın yanında diğer regularization methodlarını da göreceğiz. Dropout, Data augmentation ve Batch normalization'dan bahsedilecek.

Computer vision'a deep dive yapacağız. CNN'i göreceğiz. Ayrıca Data Ethics konusundan bahsedilecek.

# Build Models with Unlabeled Data

platform.ai sitesi ile labelı olmayan dataları kolayca labellayarak modeller eğitebiliriz.

Siteye gidip tek bil file içinde unlabeled dataset'i yükleyebiliriz. Aşağı yukarı 500 örnek model eğitmek için yeterli olur daha fazlası göz çıkarmaz tabi.

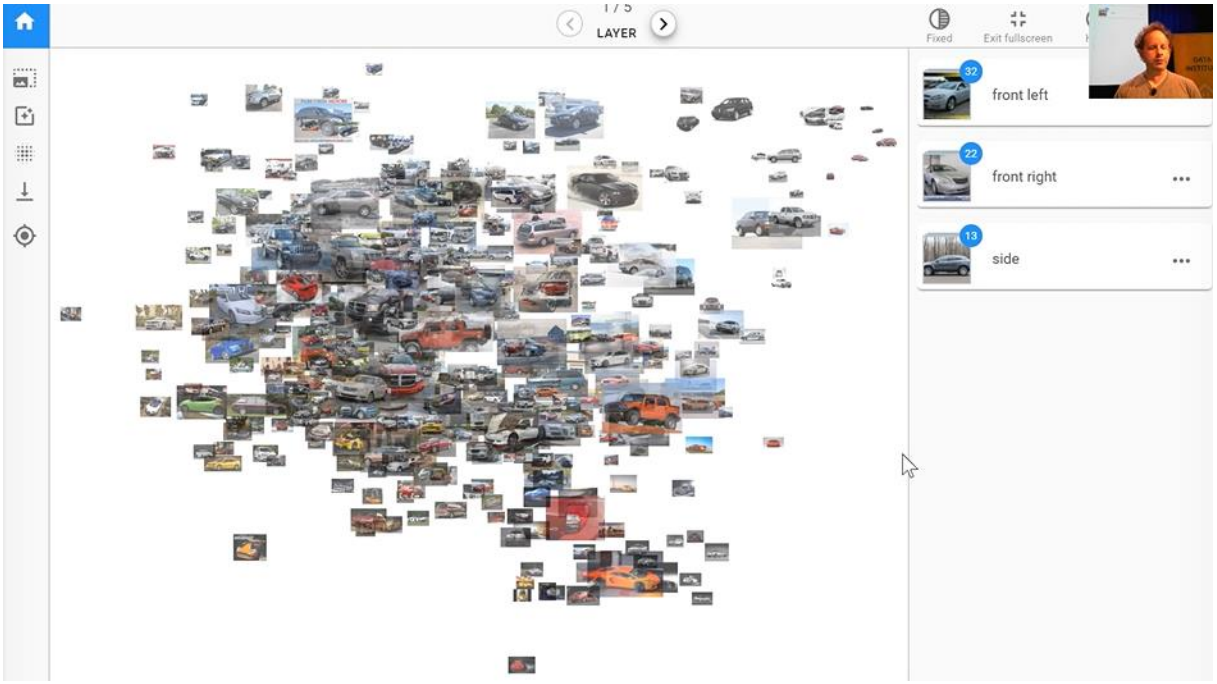


Diyelim ki bir araba datasetini aldık yükledik, yukarıdaki gibi bir görüntü elde ediyoruz. Ekranda görülenler tüm dataset değil, sadece bir random sample.

Bu resimler bir deep learning space'den 2D space'e projected hali. Yani resnet34 gibi bir imagenet model kullanılmış, yukarıda layerlar görünüyor şuanda ilk layerdayız yani burada diyelim ki ilk layerda 100 feature detect ediliyor yani dataset 100 dimensional bir uzaya dağılmış durumda ancak PCA gibi bir yöntemle ben bu dataseti 100D'den 2D'ye çekebilirim ve çekince işte yukarıdaki gibi bir dağılım elde etmişiz.

Sonuçta 2D uzayda her axis 1. Layerın yakaladığı simple feature'ların karışımını temsil ediyor, yani birbirinden farklı konumda olan images farklı simple feature'lara sahip diyebiliriz.

Bu örnekte nihai amacımız, yüklenen dataseti farklı açılardan oluşan subclass'lara ayırmak olsun, yani datayı labellayacağız, ancak bunu tek tek yapmak yerine bu tooldan yararlanarak hızlıca yapmayı amaçlıyoruz.

Ancak imagenet üzerinde eğitilen bir model arabanın farklı açılarını yakalamakta pek de iyi olmayacaktır değil mi? Çünkü imagenet spesific olarak arabalar – bisikletler – kuşlar vb. gibi ayrımlar yapmak için eğitildi, yani iki farklı açıdan çekilen arabanın ikisini de araba olarak kabul etmek için eğitildi zaten.

Yukarıdan layerları değiştirince projections da değişecektir, bu bağlamda son layer projectionları ile arabaların farklı dağılmasını beklemek pek mantıklı olmayacaktır çünkü bu layerın amacı zaten arabaların hepsini birbirine yakın konumlara atamak ki diğer objelerden ayırt edilebilsin.

Benzer şekilde ilk layer da bizim için useless olacaktır çünkü, kenar köşe gibi basit feature'lar ile angle ayırt etmek zor olabilir.

Bu sebeple farklı açıların farklı dağılımını yakalayabilmek için orta layer'a yani 3. Layer'a gidiyoruz, umuyoruz ki burada dağılım farklı olsun.

3. layer'a geldikten sonra yukarıdan projection'ı seçip 15 farklı projection arasında gezebiliriz böylece 3. Layer için kendi amacımıza uygun projectionı bulabiliriz, amacımız da şu farklı açılardan çekilmiş araba fotoğrafları ayrık şekilde dursun yani kümelenmiş olsun.

Bu noktada 2. Projection'a baktığımızda görüyoruz ki 2D projection'ın sol kısımlarındaki arabalar hep aynı angle'dan çekilmiş, işte bu noktada buraya zoom yapıyoruz ve soldan selection mode'a gelip bu fotoğrafları seçiyoruz.


Daha sonra seçilen fotoğrafları yakından inceleyip araya karışmış hatalı açıları atabilirim:

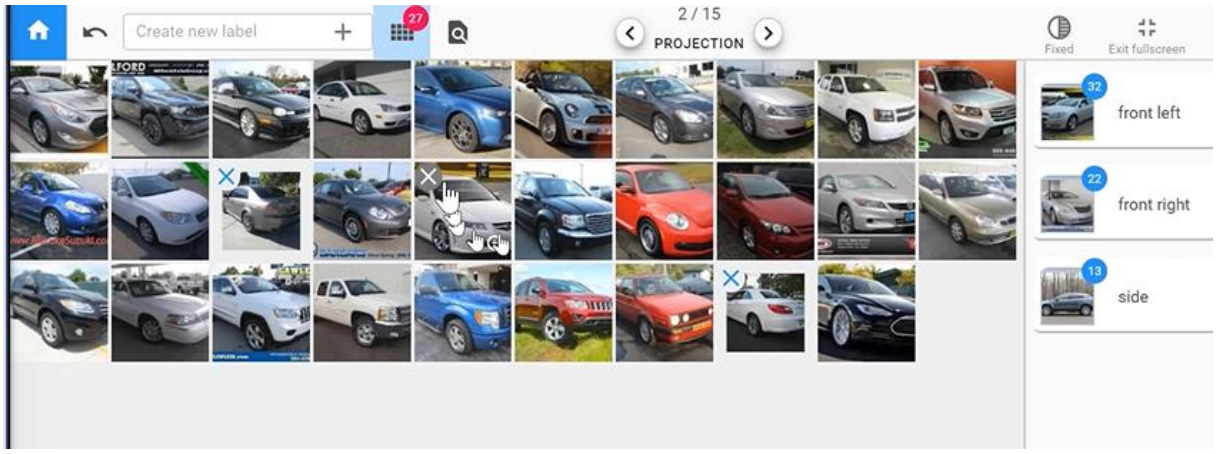


Bu seçilen fotoğraflarla yeni bir label oluşturabileceğim gibi fotoğrafları var olan bir labelın içine de taşıyabilirim.

Bu şekilde bir nevi hızlandırılmış labeling yapabiliyorum.

Ancak zamanla şunu görebiliriz ki her label'ı rahatlıkla tespit edemiyor olabilirim. Mesela bu örnekte sideview bulmakta zorlanıyoruz.

Bu problemi çözmek için yine aynı projection sayfasında sideview fotoğraflardan birkaçına tıplayıp yukarıdan find similar images seçeneğini işaretleyebilirim, böylece o projection space'de seçilen images'a benzeyen projectionlar tüm datasetten seçilip önümüze gelecek.

Ayrıca eğer diyelim ki side view ile front right view'i birbirinden ayıran bir projection bulmak istiyorum diyelim, bunu yapmak için yaratılan label klasörlerinin ikisini de seçtikten sonra sol üste switch to the projection that maximizes distance between labels seçeneğini işaretliyorum:

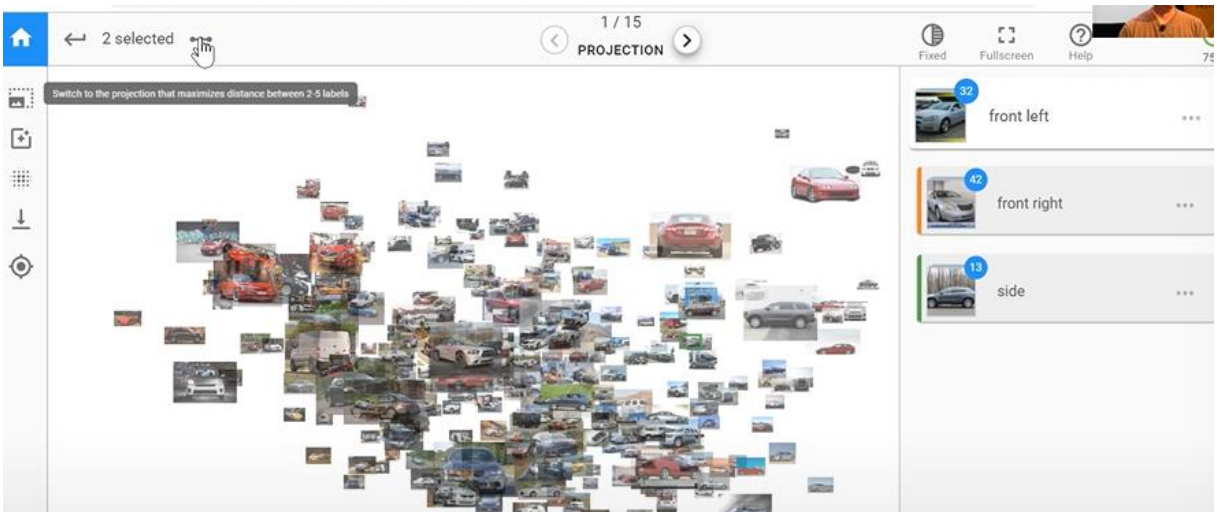


Sonuçta öyle bir 2D projection bulmak istiyorum ki side views ile front right views biribirinden ayrık dursun, böylece yeni gelen images'dan kolaylıkla istenilen angle fotoğraflarını seçebilirim.

200-300 civarı fotoğrafı ayırıp classlarımı oluşturduktan sonra soldaki train model butonu ile kolay bir şekilde modelimizi eğitebiliriz.

Sonuçta hep predictions'ı hem de labelları indirebiliriz böylece bu dataseti kendimiz daha iyi bir eğitim için kullanabiliriz.

# Tabular Model ile Kalan Regularization Methodlarını Anlamaya Çalışalım

Bu amaçla Rossmann Store Sales ismindeki kaggle competion dataset'ini kullanarak bir tabular model eğitilecek, bu kernel kaggle'da var zaten, ben buradan devam edeceğim.

Bu competition için error metric olarak RMSPE kullanılmış bunun formülü de RMSE'e çok benziyor ancak percentage olarak hesaplanıyor yani y-y_hat tekrar y'ye bölündükten sonra kare alınıyor.

$$\text{RMSPE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(\frac{y_i - \hat{y}_i}{y_i}\right)^2},$$

Bu problem için 6-7 farklı table joint edilecek kullanılacak vesaire ancak bu derste bunun detayına girmeyeceğiz, ancak bunu ben aşağı yukarı biliyorum zaten.

Yani data preperationi'ı atlıyoruz. Bu preperation işlemi rossman_data_clean.ipynb içerisinde yapılmış istersen aç bak.

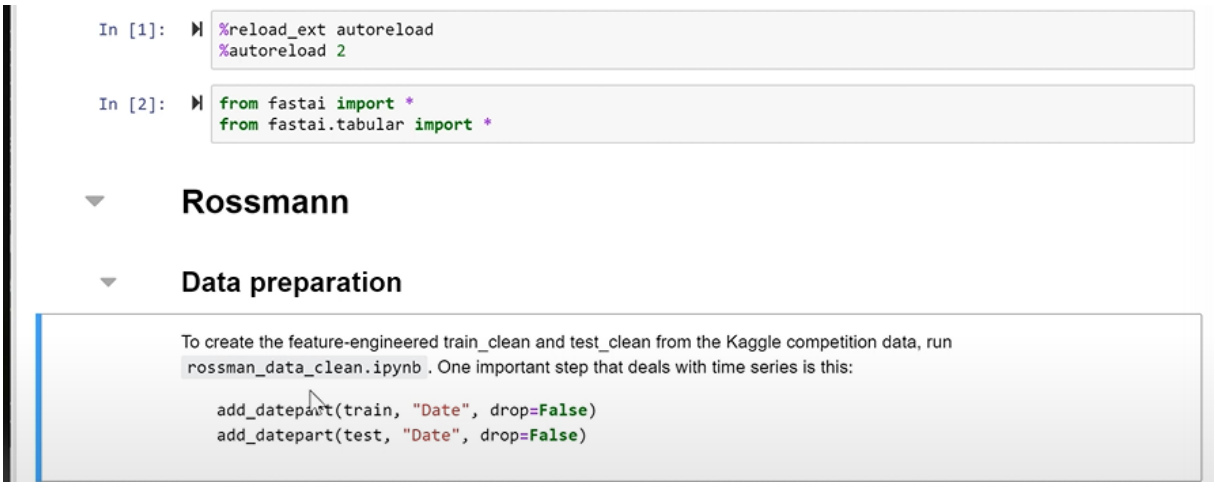


Burada önemli bir nokta preperation içindeki yukarıdaki add_datepart() kısmı. Timeseries için RNN kullanılmasını bekliyor olabilirsiniz ama kullanılmayacak, RNN'in iyi olduğu alan görünüşe göre eğer elinizdeki tek bir data varsa ve o da time series ise. Ancak gerçek hayatta neredeyse hiçbir zaman durum bu değil, genelde elimizde store'la ilgili insalarla ilgili birsürü bilgi metadata veya başka sequence veriler olur.

Bu yüzden pratikte çoğunlukla timeseries veriyi ki bu durumda bu tarih verisi oluyor, bu veriyi alıp bir sürü farklı metadataya çevirip o şekilde tabular bir model eğitmek çok iyi sonuçlar veriyor.

İşte add_datepart()'ın yaptığı şey bu, date kısmını alıyor birsürü categorical variable ekliyor bunlar, kaçıncı hafta, hangi ay, hangi gün, vesaire gibi categorical variables:

| | | | | | |
|---|---|---|---|---|---|
| Open | 1 | 1 | 1 | 1 | 1 |
| Promo | 1 | 1 | 1 | 1 | 1 |
| StateHoliday | False | False | False | False | False |
| SchoolHoliday | 1 | 1 | 1 | 1 | 1 |
| Year | 2015 | 2015 | 2015 | 2015 | 2015 |
| Month | 7 | 7 | 7 | 7 | 7 |
| Week | 31 | 31 | 31 | 31 | 31 |
| Day | 31 | 31 | 31 | 31 | 31 |
| Dayofweek | 4 | 4 | 4 | 4 | 4 |
| Dayofyear | 212 | 212 | 212 | 212 | 212 |
| Is_month_end | True | True | True | True | True |
| Is_month_start | False | False | False | False | False |
| Is_quarter_end | False | False | False | False | False |
| Is_quarter_start | False | False | False | False | False |
| Is_year_end | False | False | False | False | False |
| Is_year_start | False | False | False | False | False |
| Elapsed | 1438300800 | 1438300800 | 1438300800 | 1438300800 | 1438300800 |
| StoreType | c | a | a | c | a |
| Assortment | a | a | a | c | a |

Yani özetle dataset içindeki zaman serisi değişken'i temsil etmek için birsürü veri ekliyoruz böylece mesela ayın 15'nde payday olduğu için harcamaların arttığı gibi bir bilgiyi modelin yakalayabilmesini sağlıyoruz, modelin böyle komplex bir feature'ı başka türlü timestamp'den elde etmesi imkansız gibi bir şey.

Bu yöntemle bir çok time-series probleme regular tabular problems gibi yaklaşabiliriz, hepsine değil ancak birçoğuna böyle yaklaşabiliriz.

Sonuçta yukarıdaki gibi bir dataset'i elde ettik burada her column bir example, burada sadece ilk 5 column gösterilmiş head() ile baktığımız için, sonuçta tahmin edilmeye çalışılan şey de bu değişlenlerden birisi Sales! Yani sales is the dependent variable.

```
In [4]: train_df.head().T
```

Out[4]:

| | 0 | 1 | 2 | 3 | 4 |
|---|---|---|---|---|---|
| index | 0 | 1 | 2 | 3 | 4 |
| Store | 1 | 2 | 3 | 4 | 5 |
| DayOfWeek | 5 | 5 | 5 | 5 | 5 |
| Date | 2015-07-31 00:00:00 | 2015-07-31 00:00:00 | 2015-07-31 00:00:00 | 2015-07-31 00:00:00 | 2015-07-31 00:00:00 |
| Sales | 5263 | 6064 | 8314 | 13995 | 4822 |
| Customers | 555 | 625 | 821 | 1498 | 559 |
| Open | 1 | 1 | 1 | 1 | 1 |
| Promo | 1 | 1 | 1 | 1 | 1 |
| StateHoliday | False | False | False | False | False |
| SchoolHoliday | 1 | 1 | 1 | 1 | 1 |
| Year | 2015 | 2015 | 2015 | 2015 | 2015 |
| Month | 7 | 7 | 7 | 7 | 7 |
| Week | 31 | 31 | 31 | 31 | 31 |
| Day | 31 | 31 | 31 | 31 | 31 |
| Dayofweek | 4 | 4 | 4 | 4 | 4 |

# İlk bakacağımız şey PreProcessers:

Transforms'u görmüştük, transform dataset'ten minibatch alınırken her seferinde uygulanıyordu ve data augmentation sağlıyordu.

Preprocessors da transforms'a benziyor ancak biraz farklılar preprocessors trainingden önce tek bir kez çalışırlar, eğitim süresince çalışmaz.

Önemli nokta şu, trainings et üzerinde bir kez çalışmalarına rağmen, üretilen metadata validation ve test set ile paylaşılır, yani o dataset'e de uygulanır, yoksa training set ile diğer setlerin dağılımı değişirdi bu istediğimiz bir şey değil.

Şimdi bunları anlamak için önce bir subset dataset yaratıyorum yani bir sample yaratıyorum, önce rastgele 2000 id çekiyorum, daha sonra 1000'lik bir dataset ve ve 1000'lik bir test set yaratıyorum ve seçtiğim bazı cont ve categorical verileri çekiyorum. şimdi bu datasetlerle oynayarak yapmak istediklerimi daha rahat deneyebilirim.

### Experimenting with a sample

In [6]:
```
idx = np.random.permutation(range(n))[:2000]
idx.sort()
small_train_df = train_df.iloc[idx[:1000]]
small_test_df = train_df.iloc[idx[1000:]]
small_cont_vars = ['CompetitionDistance', 'Mean_Humidity']
small_cat_vars =  ['Store', 'DayOfWeek', 'PromoInterval']
small_train_df = small_train_df[small_cat_vars + small_cont_vars + ['Sales']]
small_test_df = small_test_df[small_cat_vars + small_cont_vars + ['Sales']]
```

In [7]:
```
small_train_df.head()
```

Out[7]:

| | Store | DayOfWeek | PromoInterval | CompetitionDistance | Mean_Humidity | Sales |
|---|---|---|---|---|---|---|
| **280** | 281 | 5 | NaN | 6970.0 | 61 | 8053 |
| **584** | 586 | 5 | NaN | 250.0 | 61 | 17879 |
| **588** | 590 | 5 | Jan,Apr,Jul,Oct | 4520.0 | 51 | 7250 |

Sub training set'e bakınca görüyoruz k, PromoInterval satırında NaN değerler var orijinal değerleri "Jan,Apr,Jul,Oct" gibi string değerler.

| | | | | | | |
|---|---|---|---|---|---|---|
| **280** | 281 | 5 | NaN | 6970.0 | 61 | 8053 |
| **584** | 586 | 5 | NaN | 250.0 | 61 | 17879 |
| **588** | 590 | 5 | Jan,Apr,Jul,Oct | 4520.0 | 51 | 7250 |
| **847** | 849 | 5 | NaN | 5000.0 | 67 | 10829 |
| **896** | 899 | 5 | Jan,Apr,Jul,Oct | 2590.0 | 55 | 5952 |

In [8]:
```
small_test_df.head()
```

Out[8]:

| | Store | DayOfWeek | PromoInterval | CompetitionDistance | Mean_Humidity | Sales |
|---|---|---|---|---|---|---|
| **428412** | 921 | 2 | NaN | 840.0 | 89 | 8343 |
| **428541** | 1050 | 2 | Mar,Jun,Sept,Dec | 13170.0 | 78 | 4945 |
| **428813** | 209 | 1 | Jan,Apr,Jul,Oct | 11680.0 | 85 | 4946 |
| **430157** | 414 | 6 | Jan,Apr,Jul,Oct | 6210.0 | 88 | 6952 |
| **431137** | 285 | 5 | NaN | 2410.0 | 57 | 5377 |

İlk bakacağımız preprocessor CATEGORIFY. Bunun yapacağı şey şu, belirtilen PromoInterval için kullanılan tüm farklı stringleri alacak bir liste yaratacak ve herbirine bir number atayacak. Training set üzerinde çağırınca kategorilerini burada yaratacak, daha sonra test set üzerinde çağırmak için test=True parametresi ile çağırınca, training set üzerindeki kategorilerin aynısını test set'e uygulayacak.

In [9]:
```
categorify = Categorify(small_cat_vars, small_cont_vars)
categorify(small_train_df)
categorify(small_test_df, test=True)
```

Uygulamadan sonra test set' bakarsak promo interval hala aynı görünüyor, ancak aslında değişim arkaplanda yapıldı pandas bize hala eski string değerleri gösteriyor.

```
In [10]: small_test_df.head()
```

Out[10]:

| | Store | DayOfWeek | PromoInterval | CompetitionDistance | Mean_Humidity | Sales |
|---|---|---|---|---|---|---|
| **428412** | NaN | 2 | NaN | 840.0 | 89 | 8343 |
| **428541** | 1050.0 | 2 | Mar,Jun,Sept,Dec | 13170.0 | 78 | 4945 |
| **428813** | NaN | 1 | Jan,Apr,Jul,Oct | 11680.0 | 85 | 4946 |
| **430157** | 414.0 | 6 | Jan,Apr,Jul,Oct | 6210.0 | 88 | 6952 |
| **431137** | 285.0 | 5 | NaN | 2410.0 | 57 | 5377 |

```
In [11]: small_train_df.PromoInterval.cat.categories
Out[11]: Index(['Feb,May,Aug,Nov', 'Jan,Apr,Jul,Oct', 'Mar,Jun,Sept,Dec'], dtype='object')
```

Değişimi anlamak için promointerval.cat.categories'e bakıyoruz ve list of classes'ı görüyoruz.

```
In [12]: small_train_df['PromoInterval'].cat.codes[:5]
Out[12]: 280   -1
         584   -1
         588    1
         847   -1
         896    1
         dtype: int8
```

Bu şekilde de classlara karşılık gelen sayı kodlarını görebilirim, -1 demek NaN demek. Tabi bu değerler bir embedding matrixde kullanılacak bu yüzden -1'ler yerine 1 kullanılıyor.?

Yani categorify'ın yaptığı şey datayı kategorik veriye çevirmek ve her birine bir sayısal kod atamak. Daha sonra her bir kategorik veri için bir embedding vector oluşturulacak ve NN için bu embedding vector kullanılacak.

Benzer şekilde bir diğer preprocessor ile FILLMISSING Bunun yapacağı şey missingleri doldurup yerine isMissing column'u eklemek, böylece hem missingi doldurmuş oluyoruz ama hatalı bir doldurma için de modele isMissing column'u ile durumu yakalama şansı veriyoruz.

```
In [13]: fill_missing = FillMissing(small_cat_vars, small_cont_vars)
         fill_missing(small_train_df)
         fill_missing(small_test_df, test=True)
```

```
In [14]: small_train_df[small_train_df['CompetitionDistance_na'] == True]
```

Out[14]:

| | Store | DayOfWeek | PromoInterval | CompetitionDistance | Mean_Humidity | Sales | CompetitionDistance_na |
|---|---|---|---|---|---|---|---|
| **78375** | 622 | 5 | NaN | 2380.0 | 71 | 5390 | True |
| **161185** | 622 | 6 | NaN | 2380.0 | 91 | 2659 | True |
| **363369** | 879 | 4 | Feb,May,Aug,Nov | 2380.0 | 73 | 4788 | True |

Preprocessors'ı manual olarak kodlamamıza gerek yok, aşağıdaki gibi processorsı tanımladıktan sonra, databunch'ımızı oluşturuken hatta ItemList'imizi oluşturuken içierinse procs=procs satırı ile processors'ı direkt tanımlayabiliriz.

```
In [17]: procs=[FillMissing, Categorify, Normalize]
```

```
In [24]: data = (TabularList.from_df(df, path=path, cat_names=cat_vars, cont_names=cont_vars, procs=procs)
                    .split_by_idx(valid_idx)
                    .label_from_df(cols=dep_var, label_cls=FloatList, log=True)
                    .databunch())
```

Böylece, missing değerleri otomatik olarak doldurcak categorify uygulayacak ve normalization(continious variables için) yapacak.

# Tabular Örneğine Devam

Tabular databunch oluşturmak için categorical ve continious variables'ı belirtmemiz gerek.

```
In [17]: procs=[FillMissing, Categorify, Normalize]

In [18]: cat_vars = ['Store', 'DayOfWeek', 'Year', 'Month', 'Day', 'StateHoliday', 'CompetitionMonthsOpen',
             'Promo2Weeks', 'StoreType', 'Assortment', 'PromoInterval', 'CompetitionOpenSinceYear', 'Promo2Si
             'State', 'Week', 'Events', 'Promo_fw', 'Promo_bw', 'StateHoliday_fw', 'StateHoliday_bw',
             'SchoolHoliday_fw', 'SchoolHoliday_bw']

         cont_vars = ['CompetitionDistance', 'Max_TemperatureC', 'Mean_TemperatureC', 'Min_TemperatureC',
            'Max_Humidity', 'Mean_Humidity', 'Min_Humidity', 'Max_Wind_SpeedKm_h',
            'Mean_Wind_SpeedKm_h', 'CloudCover', 'trend', 'trend_DE',
            'AfterStateHoliday', 'BeforeStateHoliday', 'Promo', 'SchoolHoliday']

In [19]: dep_var = 'Sales'
         df = train_df[cat_vars + cont_vars + [dep_var,'Date']].copy()

In [20]: test_df['Date'].min(), test_df['Date'].max()

Out[20]: (Timestamp('2015-08-01 00:00:00'), Timestamp('2015-09-17 00:00:00'))

In [21]: cut = train_df['Date'][(train_df['Date'] == train_df['Date'][len(test_df)])].index.max()
         cut

Out[21]: 41395
```

Sadece stringleri değil başka değişkenleri de categorical olarak işleyebiliriz. Mesela day of month aslında 1-30 arasında bir number olmasına rağmen biz bunu categorical olarak aldık. Ancak ayın 1 ile 15 ile 30'u aslında farklı purchase behaviour gösterebilir. Bunu yakalayabilmek için bazı variable'ları categorical seçiyoruz.

Eğer cardinality çok yüksek değilse yani categorical'a çevirince mesela day of month için cardinality 30 bu yüzden yüksek olmayanları her zaman categorical olarak almakta fayda var.

Sonuçta birkaç stepten sonra tabular databunch'ı oluşturuyoruz.

Burada label_cls=FloatList şeklinde bir ibare var, bunu daha önce görmedik.

Dependent variable'a baktığımız zaman dtype:int64 olarak görünüyor, eğer bu değerler float olursa fastai problemin bir regression problemi olduğunu anlar, aksi halde bunu classification olarak kabul eder. Bu yüzden labeling yaparken list of floats kullanıyoruz ki fastai problemin regression olduğunu anlasın.

```
In [23]: df[dep_var].head()

Out[23]: 0     5263
         1     6064
         2     8314
         3    13995
         4     4822
         Name: Sales, dtype: int64

In [24]: data = (TabularList.from_df(df, path=path, cat_names=cat_vars, cont_names=cont_vars, procs=procs)
                            .split_by_idx(valid_idx)
                            .label_from_df(cols=dep_var, label_cls=FloatList, log=True)
                            .databunch())

In [28]: doc(FloatList)
```

Log=True ibaresi de y değerinin log'unu alır, bunu yapmamın sebebi loss olarak RMSE kullanabilmek, log alıp RMSE kullandığım zaman bu log almadan RMSPE kullanmakla aynı kapıya çıkıyor.

# Databunch'ımızı oluşturduktan sonra modele geçebiliriz:

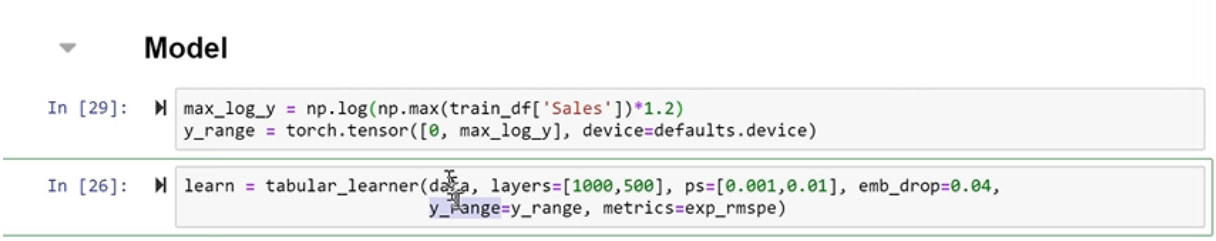


Gördüğümüz gibi model için y_range tanımlıyoruz bunu yapınca modelin sonuna bir sigmoid ekliyorduk ve regression problemi için modeli tahmin sınırlarını öğrenme derdinden kurtarıyorduk.

Max değeri hespalarken 1.2 çarpanının sağladığı şey, sigmoidin üst sınırının gerçek maksimumdan %20 daha üstte olmasını sağlamak böylece modelimiz max değeri çıktı olarak verebilecek.

Tabular learner içine databunch'ımızı ve y_range'imizi ve metriğimizi vediğimizi zaten biliyoruz bunun yanında yukarıda görülen başka parametreler de var.

Layers'ı 1000'e 500 olarak tanımlıyoruz böylece intermediate weight matrix 50 000 weight'e sahio olacak bu datasetimiz için çok fazla bir rakam, yani overfit olacağı garanti, ancak overfiti engellemek için parametreden kısmıyorduk, onun yerine regularization kullanıyorduk işte diğer parametrelerin tanımladığı şey de bu, dropout regularization parametreleri tanımlanmış.

Weight decay regularization zaten otomatik olarak kullanıyor, istersek değerini değiştirebiliriz.

Daha fazla regularization istediğimiz için dropout kullanıyoruz.

Dakika 31:00 civarı dropouttan bahsediyor özetle, random olarak unitleri deactivate ederek, unitlerin belirli feature'ları ezberleyerek sonucu bulmasını engelliyoruz.

Fastai learner için bir list olarak p values geçirebiliriz böylece ayrı ayrı layer'lar için dropout probability'sini geçirebiliriz yada tek bir değer gireriz ve tüm layerlar için bu değer kullanılır.

Normalde test time için dropout çalışmadığı için, training sırasında kullanılandan daha fazla layer kullanılır dolayısıyla output'un daha yüksek çıkması beklenir, bunu engellemek için test time'da weights'i p ile çarpmak bir yöntem.

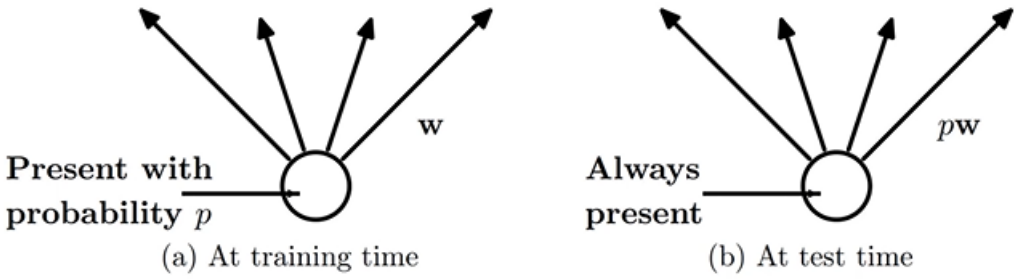

(a) At training time (b) At test time

Ancak pytorch training sırasında yapılan bir trick ile bu durumu ortadan kaldırmış, yani test time'da weights'i p ile çarpmamıza gerek kalmamış. Çünkü onun yerine training time'daki pediction manipüle edilerek test time ile eşitlenmiş . Aşağıdaki kod sayesinde.

```
noise.bernoulli_(1 - p);
noise.div_(1 - p);
return multiply<inplace>(input, noise);
```

Emb_Drop=0.04 de embedding layerda kullanılan bir special dropout'ı işaret eder. Yani embedding aktivasyonlarından bazılarını random olarak kaldırıyoruz, sonuçta embedding layer da de bir layer. Bu sonuca experimental olarak ulaşmış sanıyorum.

Modelimizin içeriğine learn.model ile bakabiliriz:

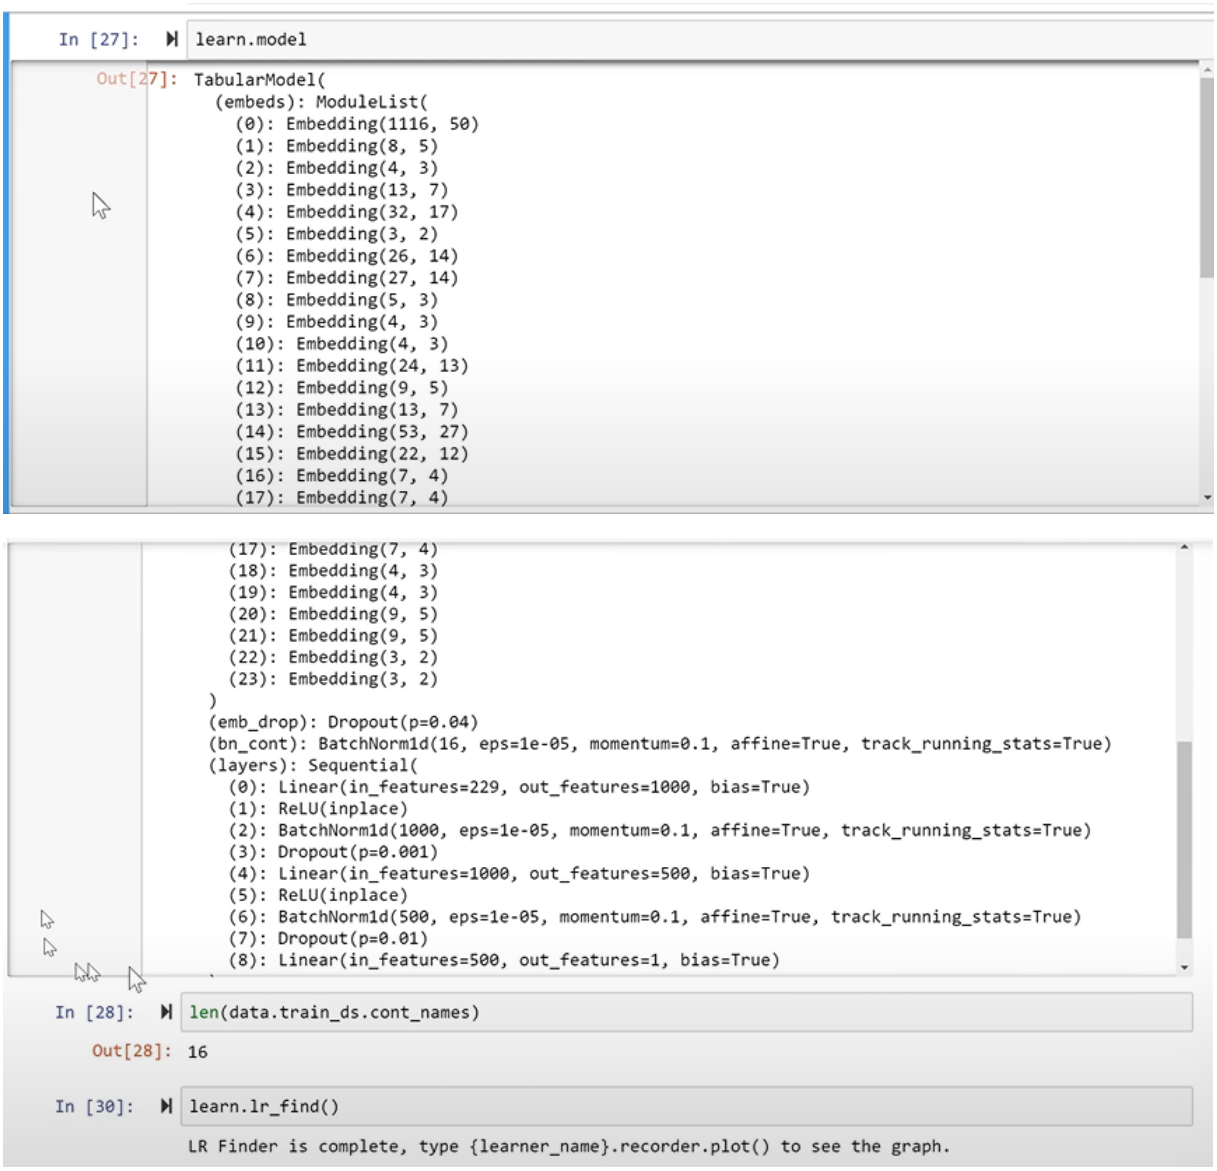

```
In [27]: learn.model

Out[27]: TabularModel(
  (embeds): ModuleList(
    (0): Embedding(1116, 50)
    (1): Embedding(8, 5)
    (2): Embedding(4, 3)
    (3): Embedding(13, 7)
    (4): Embedding(32, 17)
    (5): Embedding(3, 2)
    (6): Embedding(26, 14)
    (7): Embedding(27, 14)
    (8): Embedding(5, 3)
    (9): Embedding(4, 3)
    (10): Embedding(4, 3)
    (11): Embedding(24, 13)
    (12): Embedding(9, 5)
    (13): Embedding(13, 7)
    (14): Embedding(53, 27)
    (15): Embedding(22, 12)
    (16): Embedding(7, 4)
    (17): Embedding(7, 4)
    (18): Embedding(4, 3)
    (19): Embedding(4, 3)
    (20): Embedding(9, 5)
    (21): Embedding(9, 5)
    (22): Embedding(3, 2)
    (23): Embedding(3, 2)
  )
  (emb_drop): Dropout(p=0.04)
  (bn_cont): BatchNorm1d(16, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
  (layers): Sequential(
    (0): Linear(in_features=229, out_features=1000, bias=True)
    (1): ReLU(inplace)
    (2): BatchNorm1d(1000, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (3): Dropout(p=0.001)
    (4): Linear(in_features=1000, out_features=500, bias=True)
    (5): ReLU(inplace)
    (6): BatchNorm1d(500, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (7): Dropout(p=0.01)
    (8): Linear(in_features=500, out_features=1, bias=True)

In [28]: len(data.train_ds.cont_names)

Out[28]: 16

In [30]: learn.lr_find()
LR Finder is complete, type {learner_name}.recorder.plot() to see the graph.
```

Beklediğimiz gibi birsürü embedding var her categorical variable için (cardinality, custom dimension) boyutlarında bir matrix vardır yani mesela 1116 tane store varmış ve herbirini temsil etmek için 50 parametre kullanılmış, bir store NN'e input olarak verileceğinde lookup ile bu 50 elemanlı vektör kullanılıyor sanıyorum ve her kullanımdan sonra da bu vektörlerin weightleri update ediliyor en sonunda hem biz kategorik verilerimizi algoritmamızda kullanmış oluyoruz hem de her kategorik veriyi temsil eden feature'lar öğrenmiş oluyoruz böylece farklı kategorik verilerin arasındaki ilişkiler keşfedilinebiliyor.

16 tane continious variable'ım var, bu yüzden yukarıdaki cont_names satırında 16'yı elde ettik.

Modelimin layerlarına bakarsak Embedding dropout'tan sonra bir 16 inputlu bir batchNorm layer görüyoruz çünkü 16 tane continious variable'ım var.

Yani batchNormalization continious variables için kullanılıyor.

# BatchNorm Nedir?

Ne olduğu belirsiz bir şey. Biraz regularization gibi biraz training helper gibi bir şey.

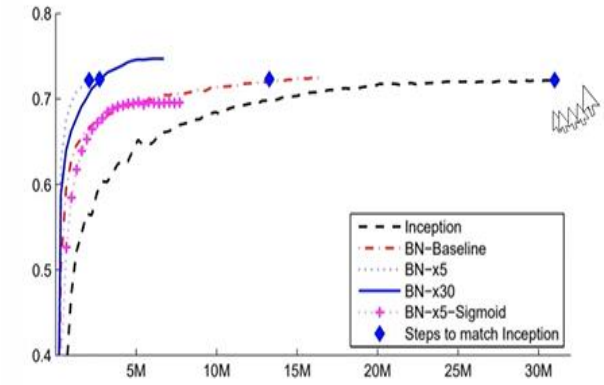


Figure 2: *Single crop validation accuracy of Inception and its batch-normalized variants, vs. the number of training steps.*

**Input:** Values of $x$ over a mini-batch: $\mathcal{B} = \{x_{1...m}\}$;
Parameters to be learned: $\gamma, \beta$
**Output:** $\{y_i = \mathrm{BN}_{\gamma,\beta}(x_i)\}$

$$\mu_{\mathcal{B}} \leftarrow \frac{1}{m}\sum_{i=1}^{m} x_i \qquad \text{// mini-batch mean}$$

$$\sigma^2_{\mathcal{B}} \leftarrow \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_{\mathcal{B}})^2 \qquad \text{// mini-batch variance}$$

$$\widehat{x}_i \leftarrow \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma^2_{\mathcal{B}} + \epsilon}} \qquad \text{// normalize}$$

$$y_i \leftarrow \gamma \widehat{x}_i + \beta \equiv \mathrm{BN}_{\gamma,\beta}(x_i) \qquad \text{// scale and shift}$$

**Algorithm 1:** Batch Normalizing Transform, applied to activation $x$ over a mini-batch.

Batch norm ile çok daha düşük training step ile yüksek accuracy'e ulaşabiliyoruz, ancak neden işe yaradığını açıklayanlar yanıldılar. Yeni bir açıklamaya göre batch normalization'ın covariance shift'i azaltmadığı ortaya çıkmış yani nasıl işe yaradığı biraz muğlak.

Aşağıda görüldüğü gibi batch norm ile eğitim yapılınca loss çok daha az bumpy bu şu demek, batch norm yokken küçük bir parametre değişimi loss'da büyük zıplamalara yol açıyor veya bir başka deyişle loss function'ın çok engebeli olmasına yol açıyor bu yüzden learning rate büyütemiyorduk ancak batch normalization ile daha temiz bir cost function elde ederek, learning rate'i büyüyebiliyoruz ve böylece global minimum'a çok daha hızlı şekilde ulaşabiliyoruz.

**How Does Batch Normalization Help Optimization?**


**Shibani Santurkar*** MIT shibani@mit.edu

**Dimitris Tsipras*** MIT tsipras@mit.edu

**Andrew Ilyas*** MIT ailyas@mit.edu

**Aleksander Mądry** MIT madry@mit.edu



"the positive impact of BatchNorm on training might be somewhat serendipitous"

# What batchNorm does?

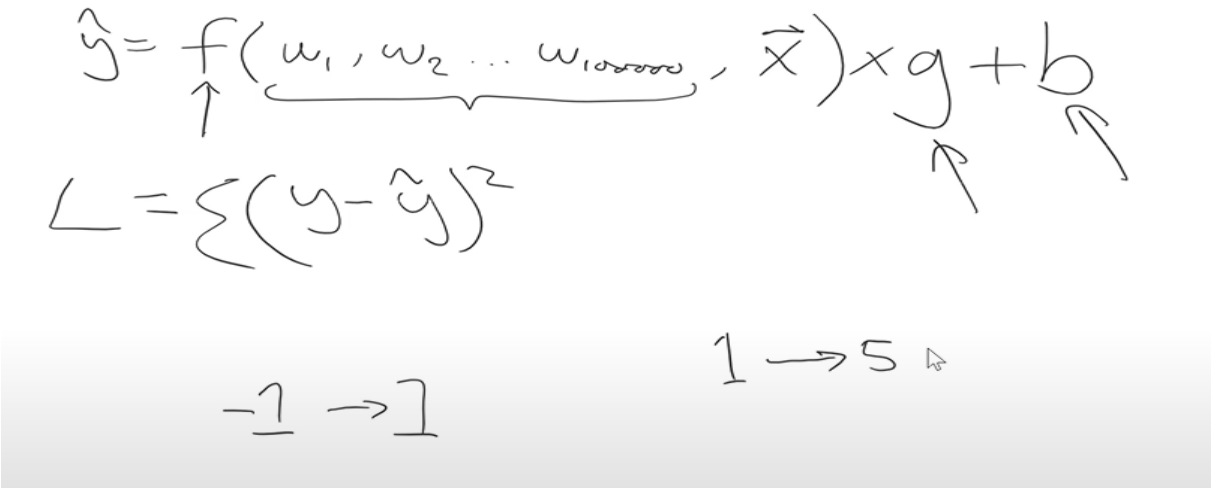


Diyelim ki, outputumun 1-5 arasında olmasını istiyorum ancak aktivasyon sonucu -1 ile 1 arası çıkıyor bunu değiştirmek için weightleri scale edemem. Onun yerine basitçe aktivasyonun çıkışını bir g ile çarparsam ve b eklersem -1 ile 1 arasında çıkış veren bir NN'i basit bir çekilde 1-5 arasında çıkış vermeye itebilirim ayarlaması gereken tek şey 2 parametre. Batch norm'un sağladığı şey bu.

Batch norm makes it easier to shifting outputs up and down and in and out.

Detaylar önemli değil ama ÇOK İYİ ÇALIŞIYOR KESİNLİKLE KULLANMALIYIZ.

Her continious variable için bir batch norm layer kullanılıyor.

Modeli oluşturduk, ve detaylarından bahsettik.

Bu noktadan sonra lr_find() veya fit ile hep yaptığımız şeyleri yapabiliriz detaylar için kernel'e bakabilrsin.

SORU: Hangi regularization methodlarını ne zaman kullanmalıyız?

CEVAP: Weight Decay, Dropout, Data Augmentation ve Dropout'u düşündüğümğz zaman, batch norm'u her zaman kullanmak isteriz, data augmentation'dan az sonra bahsedeceğiz. Weight Decay ile Dropout arasında nasıl bir seçim yapılacak bilmiyoruz, kimse bilmiyor ikisini karıştıralım mı, ayrı ayrı mı kullanalım hangisi verimli kimsenin fikri yok. Ama sanki ikisinden de biraz kullanmak pratikte yararlı gibi duruyor biraz weight decayi neredeyse her zaman isteriz, birazcık dropout da fena olmuyor, bunları deneyip görmek lazım. Default değerler genelde gayet iyi çalışır ama istersen tabi deneme yapabilirsin.

## Sonuçta Tabular Data konusunu kapattık kapatırken de Dropout ve Batch Normalization'ı da aradan çıkardık şimdi yeni bir örnek ile Data Augmentation'dan bahsedelim:

Jeremy'e göre üzerinde en az çalışılan regularization metodu data augmentation buna karşın data augmentation'ın çok değerli olabileceğini söylüyor çünkü data augmentation'ın neredeyse hiç cost'u olmadığını söylüyor.

Data augmentation ile daha iyi bir generalization sağlayabiliriz ve bunu yaparken daha fazla eğitime gerek duymayız veya underfitting riski taşımayız.

Data augmentation'ı anlamak için daha önce kullanılan PETs datasetine geri dönüyoruz.

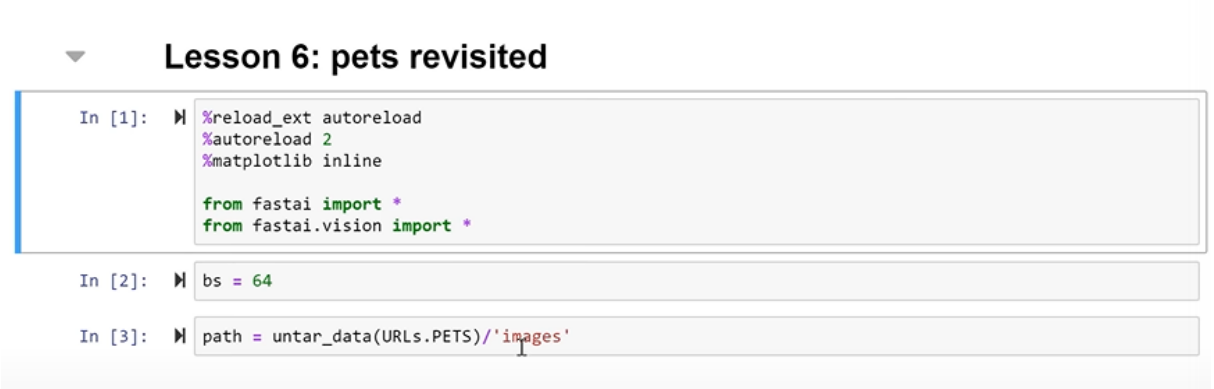


Data augmentation için get_transform satırı değerli. Burada bir çok transform'u belirttik tüm bunları anlamak için doc(get_transforms) ile documentation'a bakabiliriz.

```
In [9]:
def _plot(i,j,ax):
    x,y = data.train_ds[3]
    x.show(ax, y=y)

plot_multi(_plot, 3, 3, figsize=(8,8))
```


Data augmentation ile free extra data kazanmış oluyoruz, farklı açıları farklı brightness değerleri rotation'ı ve daha bir çok şeyi hesaba katıyoruz böylece test datasını çok daha iyi bir şekilde genelleyebiliyoruz.

Data augmentation'ı diğer domain'lerde nasıl gerçekleştirebileceğimizi hala bilmiyoruz bunu anlamak büyük bir adım olurdu.

# Şimdi Convolution'ı Anlamaya Çalışacağız:

Bir CNN yaratıyorum, biraz eğitiyorum unfreeze ediyorum sonra larget dataset için biraz daha eğitiyorum.

## Train a model

```
In [12]:
gc.collect()
learn = create_cnn(data, models.resnet34, metrics=error_rate, bn_final=True)
```

```
In [12]:
learn.fit_one_cycle(3, slice(1e-2), pct_start=0.8)
```

```
Total time: 00:52
epoch  train_loss  valid_loss  error_rate
1      2.413196    1.091087    0.191475    (00:18)
2      1.397552    0.331309    0.081867    (00:17)
3      0.889401    0.269724    0.068336    (00:17)
```

```
In [13]:
learn.unfreeze()
learn.fit_one_cycle(2, max_lr=slice(1e-6,1e-3), pct_start=0.8)
```

```
Total time: 00:44
epoch  train_loss  valid_loss  error_rate
1      0.695697    0.286645    0.064276    (00:22)
2      0.636241    0.295290    0.066982    (00:21)
```

```
In [14]: data = get_data(352,bs)
         learn.data = data

In [15]: learn.fit_one_cycle(2, max_lr=slice(1e-6,1e-4))

         Total time: 01:32
         epoch  train_loss  valid_loss  error_rate
         1      0.626780    0.264292    0.056834    (00:47)
         2      0.585733    0.261575    0.048038    (00:45)

In [16]: learn.save('352')
```

Sonuçta eğitilmiş bir CNN'im var.

**Sırada CNN'in ne yaptığını anlmaya çalışacağız bunu yapmak için de aşağıda görüldüğü gibi bir heat map'in nasıl oluşturulduğunu anlayacağız bu heat map bana CNN'in classification'ı yaparken inputun hangi kısımlarına odaklandığını gösteren bir heat map.**

```
In [37]: show_heatmap(avg_acts)
```

Bu heatmap'i sıfırdan elde edeceğiz. Bunun için neredeyse hiç fastai kullanmayacağız. Bu yüzden biraz yeni görünebilir, anlamayabilirsin dert değil, notebook'a git dene yanıl, geri gel tekrar dinle falan diyor, ben bi dinleyeceğim sadece, zaten CNN mantığını biliyorum Jeremy'den de dinlemiş olayım.

Dakika 1:07:00'da başlıyor. 1:34:00'a kadar zaten bildiğim CNN mantığını anlatıyor.

# Peki HeatMap'i nasıl oluşturacağız?

Sonuçta olan şey şu RGB image input olarak giriyor convolutional layerlar sonucun 11x11x512 boyutunda bir map elde ediliyor bunu fully connected layer'a çevirmek için average pooling kullanıyor 11x11 pooling yapıyor ve sonuçta 512 outputlu bir layer elde ediyor ve daha sonra fully connected layers ile 37 outputlu bir layer ile sonlanıyor.

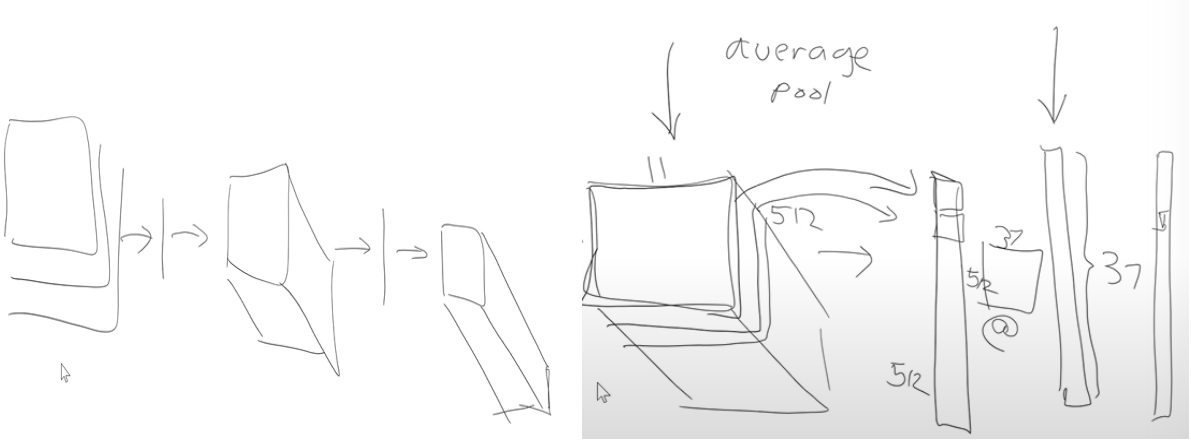


Heat map'i elde etmek için kullanılan fikir şu: 512'lik fc layer'ın her bir elemanı neyi temsil eder? Amacımız pet breeds'i ayırmak olduğu için 512 tane pet feature'ı temsil eder, image'in tamamına bakılınca ilgili feature'ın detect edilme seviyesini temsil eder.

Ondan bir önceki layerda ise 11x11x512 bir map tensorumuz var, bunun her 11x11'lik kısmı bir filter'ın sonucunu veriyor, 11x11'lik map'in her bir unit'i de ilgili filter'ın resmin ilgili kısımında o feature'ın ne kadar detect edildiğini gösteriyor.

E bizim amacımız hangi feature'ın ne kadar detect edildiği değil amacımız, genel olarak resmin hangi kısımlarında feature'ların daha çok detect edildiği olacak o zaman 11x11x512'lik map'in average pooling'ini 11x11'lik kısımlar için değil de 512lik kısım için alırsak sonuçta elimizde 11x11 bir tensor kalacak bunun her elemanı resmin ilgili bölgesinde ne kadar çok feature detect edildiğini temsil edecek. İşte heatMap'i böyle elde edebiliriz.

Bunun kodlamasını da gösteriyor, gerekirse bakabilirsin.

# Ethics and Data Science

Önümüzdeki derste Generative Models'e bakacağız yani bir text veya image veya video yaratabilecek modellere bakacağız. Bunlara girmeden önce ethics'den bahsetmeyi doğru görmüş.